


1. La tâche

Relier chaque mention de santé d'un texte français à un identifiant de référence : GeoNames pour les lieux, MeSH pour les pathogènes, maladies et toxines, ou NIL sinon. Le cadre est celui des très faibles ressources : 40 documents et 491 entités annotées à l'entraînement, 200 documents et 1 840 mentions au test. Aucun modèle n'est appris, ce qui limite le risque de surapprentissage.

2. Le système : une cascade, le modèle en dernier recours

Chaque mention traverse une cascade de règles déterministes : normalisation, puis génération de candidats propre au référentiel. Le grand modèle de langue n'intervient que si au moins deux candidats subsistent : il choisit un numéro dans une liste fermée et ne génère jamais d'identifiant.



Exemple réel du corpus d'entraînement (lieu). « Ipswich », ambiguë entre treize homonymes, est résolue vers le Royaume-Uni grâce à l'indice « société britannique ». Côté MeSH, la cascade enchaîne MeSH officiel français, dictionnaire curé puis index anglais (translittération du grec, α → alpha).

3. Trois modèles, un score plafonné

Trois modèles très différents obtiennent le même RANKING d'entraînement, 92,22, avec les mêmes F1 par référentiel. Au-delà d'un seuil, le score ne dépend plus du modèle ni de sa taille.

Table 1 – Score d'entraînement selon le modèle de désambiguïsation.


Modèle (étape 5)	RANKING	F1 GeoNames	F1 MeSH
GPT-5.4-nano (API)	92,22	91,06	94,74
gemma-4-31b (local)	92,22	91,06	94,74
Qwen3.6-35B-A3B (local)	92,22	91,06	94,74
Qwen2.5-72B (local)	91,59	90,08	94,74
Qwen2.5-32B (local)	91,59	90,08	94,74
Qwen2.5-7B (local)	87,33	83,58	94,74

4. Résultats sur le jeu de test

Table 2 – Scores officiels sur le jeu de test (1 840 mentions).


Soumission	Config.	InKB part.	NEL F1	RANKING
run 1	gemma local	83,36	85,67	84,52
run 3	API	82,97	85,27	84,12
run 2	généraliste	80,58	83,92	82,25
médiane	19 soum.	73,73	75,18	74,46

5. Profil d'ambiguïté : quand intervient le modèle ?



6. D'où viennent les erreurs ?

Deux familles d'erreurs, qui tiennent à la liste de candidats plus qu'au modèle. Granularité : sur 24 erreurs de lieux, 16 ont le bon lieu dans la liste mais au mauvais niveau administratif (« Cannes » liée à la commune et non à la localité). Le candidat est présent, mais le choix se trompe. Couverture : 6 lieux et des toxines n'ont aucun candidat produit (2 lieux restent hors du rang retenu), et aucun reranker ne choisit ce qui n'a pas été généré.



7. Généralisation entraînement → test

Table 3 – Rappel et F1 par référentiel (run 1).

Référentiel	Mesure	Train	Test	Δ
GeoNames	Rappel	91,80	88,73	−3,07
	F1	91,06	89,04	−2,02
MeSH	Rappel	92,73	73,93	−18,80
	F1	94,74	79,34	−15,40

GeoNames ne perd que deux points de F1 entre l'entraînement et le test. MeSH en perd 15 points, surtout par l'effondrement du rappel (de 92,73 à 73,93) : l'index géographique large couvre mieux le test que le dictionnaire MeSH curé à la main.

8. Empreinte carbone

Table 4 – Empreinte carbone estimée (g équivalent CO₂).

Soumission	g éq. CO ₂
run 1 : gemma local (mesuré, Green Algorithms)	≈ 1,15
run 2 et run 3 : API (estimé, EcoLogits)	1,8 à 4,0 / run
Total des trois soumissions	4,8 à 9,0

9. Conclusion

- Le goulot, c'est la liste de candidats, à deux titres :
 - couverture : un référent non généré, aucun modèle ne le rattrape, et le rappel MeSH s'effondre au test
 - granularité : le bon lieu est présent, mais à un mauvais niveau administratif
- Le modèle n'est pas le facteur limitant : trois modèles très différents font le même score, et un modèle ouvert local égale une API propriétaire
- Le progrès viendra de meilleures ressources et de métadonnées plus riches, pas d'un modèle plus gros